

МИНИСТЕРСТВО НАУКИ И ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
СИБИРСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ

Б. С. Добронез, О. А. Попова

Модели и методы обработки и анализа данных

УЧЕБНОЕ ПОСОБИЕ

Красноярск
СФУ
2023

УДК 519.2
ББК 32.81

Рецензенты:

М.Н. Фаворская доктор технических наук, профессор.

О.С. Исаева, доктор технических наук, с.н.с.

Добронец, Б. С.

Д Модели и методы обработки и анализа данных: Учебное пособие / Б. С. Добронец, О. А. Попова — Красноярск: Сиб. федер. ун-т, 2023. — 75 с.

ISBN ????

Учебное пособие содержит теоретический материал и вопросы для самоконтроля по разделам дисциплины «Интеллектуальный анализ данных», а также методические материалы к практическим и самостоятельным работам. Предназначено для магистров, обучающихся по программе подготовки 09.04.02 «Информационные системы и технологии», 09.04.01 «Информатика и вычислительная техника». Представленные в пособии материалы могут быть полезны магистрам и аспирантам других направлений и специальностей, а также для магистров, аспирантов и специалистов, занимающихся научными исследованиями и работающих в области обработки и анализа данных. Данное учебное пособие может быть использовано при изучении дисциплин, полностью или частично посвященным моделям и методам обработки и анализа данных. К ним относятся дисциплины: «Обработка экспериментальных данных», «Интеллектуальные информационно-управляющие системы».

Электронный вариант издания см.:

<http://catalog.sfu-kras.ru>

УДК 519.2

ББК 32.81

© Сибирский федеральный
университет 2023

ISBN ???

Оглавление

Введение	5
1 Современные подходы к обработке и анализу данных	7
1.1. Интеллектуализация подходов к обработке и анализу данных	7
1.2. Типы данных	10
1.3. Предобработка данных	12
1.4. Современные методологии исследования данных	16
1.5. Системы и платформы для интеллектуальной обработки данных	18
1.6. Вопросы для самоконтроля	24
2 Математические методы для аналитики данных	26
2.1. Кластеризация и классификация	26
2.2. Метод опорных векторов (SVM)	28
2.3. Кластеризация методом k-средних	34
2.4. Кластеризация методом k-NN	37
2.5. Деревья решений	39
2.6. Случайные леса	44
2.7. Метод главных компонент	47
2.8. Ассоциативные правила	51
3 Визуальная аналитика многомерных данных	58
3.1. Визуально-интерактивная аналитика	58
3.2. Методы анимации в представлении данных	60
4 Математические модели и методы агрегирования данных больших объемов	65
4.1. Определение понятия и математических моделей агрегирования данных	65
4.2. Построение гистограммы	67

4.3. Построение сплайна, проходящего через середины гистограмм	67
4.4. Построение сглаживающего сплайна	68
5 Методические материалы к выполнению самостоятельных заданий	70
5.1. Задания для самостоятельной работы	70
5.2. Пример содержательного описания объекта исследования .	71
5.3. Вопросы для самопроверки	72
Список литературы	73

Введение

Разнообразные потоки данных становятся сегодня частью нашей действительности, влияя на наше восприятие окружающего мира, в том числе в вопросах принятия решений. Одной из актуальных задач, стоящих перед исследователями и практиками является задача разобраться в огромном сложном мире данных и использовать полученные знания во благо решения поставленных задач.

Сегодня без помощи современных технологий и компьютерных систем, реализующих современные модели и методы анализа данных, трудно представить деятельность, как больших, так и малых предприятий, учреждений и фирм различного профиля деятельности.

Специалистам сегодня предлагаются для использования разнообразное аппаратное, программное и математическое обеспечение, пакеты прикладных программ (ППП), например, SAS, SPSS, Statistica, Mathcad, MatLab, Matematica, программно-аналитические платформы (например, Loginom)).

Важно, чтобы пользователь не стал механическим приложением к ним, слепо использующим возможности современных вычислительных систем без глубокого погружения и проникновения в сущность соответствующих математических проблем и их алгоритмического завершения.

Поэтому знания в области обработки данных, использования моделей и методов анализа, направленные на формирование компетенций пользователя исследовать свойства данных, выявлять взаимосвязи в них, интерпретировать результаты, полученные на основе применяемых подходов, являются сегодня необходимой составляющей профессиональной подготовки для современного специалиста, особенно там, где принимаются управленческие решения.

Модели и методы обработки и анализа данных позволяют средствами компьютерного и математического моделирования строить математические модели, отвечающие сути решаемой проблемы, а также ограничениям и структурному разнообразию эмпирических данных с учетом различных видов неопределенности.

Данное учебное пособие может быть использовано при изучении дисциплин, полностью или частично посвященным моделям и методам обработки и анализа экспериментальных данных (измерений, испытаний, опытов), вопросам преобразования и моделирования данных в условиях моделирования. Это такие дисциплины как: Интеллектуальный анализ данных, Обработка экспериментальных данных, Интеллектуальные информационно-управляющие системы, Численный вероятностный анализ.

Глава 1

Современные подходы к обработке и анализу данных

1.1. Интеллектуализация подходов к обработке и анализу данных

В настоящее время все более популярным становится понятие «интеллектуальный». Его смысловое значение определяется, как правило, объектом или предметом исследования. Например, интеллектуальная обработка данных, интеллектуальный анализ данных, интеллектуальные информационно-управляющие системы. Но есть одно важное связующее звено, которое придает понятию интеллектуальный необходимый содержательный смысл. Это понятие «знание».

Рассмотрим, что же понимается под интеллектуальной обработкой данных. Отметим, что это достаточно новое и не устоявшееся понятие. Достаточно часто оно заменяется или подменяется понятием «интеллектуальная обработка информации». Данное определение может применяться с целью подчеркнуть специфику изучаемых данных и предметную область исследования. Например, в интернете можно найти такое определение, как «интеллектуальная обработка информации (ИОИ) — одно из направлений цифровизации, целью которого является анализ и интеллектуальная обработка текстовой информации». А вот еще одно определение, которое, раскрывает анализ данных, через понятие обработка данных, а именно: «интеллектуальный анализ данных — это обработка информации и выявление в ней моделей и тенденций, которые помогают принимать решения».

Так что же все-таки составляет содержательный смысл понятия «интеллектуальная обработка данных»? Интеллектуальная обработка данных — это обработка различных массивов данных, включая структурированные,

слабо структурированные, неструктурированные данные, которые могут представлять собой значения качественных или количественных признаков, представляющие собой большие, сверх большие объемы информации (Big Data) или малые, сверх малые объемы (малые выборки) с целью выявления новой, интерпретируемой и логически понятной, практически значимой информации, которая представляет собой знания. Для этих целей применяются различные методы и технологии, которые объединяются под одним понятием «Интеллектуальный анализ данных». Например, основной целью интеллектуального анализа текстов является превращение неструктурированной текстовой информации в пригодный для дальнейшей работы набор структурированных данных в удобном для машинной обработки виде.

Отметим, что при решении большинства практических задач требуется для объяснения вникающих ситуаций выдвижение предположений. Такие задачи решаются с использованием специалистов, которые решают их, используя знания и опыт. Часть знаний можно извлечь из данных, которые подвергаются обработке и анализу. Такие знания называют «скрытыми», они содержатся в хранилищах Big Data. Для обнаружения подобных знаний применяют методы Data Mining или интеллектуальный анализ данных.

Полученные знания должны удовлетворять ряду требований, выполнение которых будет означать их полезность [13].

Найденные знания должны неизвестными ранее.

Важно отметить требование нетривиальности, не очевидности найденных знаний.

Важна практическая направленность найденных знаний.

Важно при этом логическое понимание найденных знаний и закономерностей.

Data Mining или интеллектуальный анализ данных позволяет находить новые не тривиальные знания и закономерности в Big Data.

Григорий Пятецкий-Шапиро считается основоположником направления Data Mining или «интеллектуальный анализ данных» и KDD (knowledge discovery in data).

Таким образом можно считать что, Data Mining набор инструментов для обнаружения неизвестных, нетривиальных, практически значимых и доступных интерпретации знаний, необходимых для принятия решений в различных сферах человеческой деятельности.

Data Mining лежит на пересечении нескольких наук, главные из которых — это системы баз данных, статистика и искусственный интеллект.

Интеллектуальный анализ данных используется в Big Data, источники данных наука, медицина, бизнес.

Виды информации, с которыми работает интеллектуальный анализ данных включает цифровые данные, текстовую информацию, графическую, видео и т. д.

Интеллектуальный анализ данных использует различные модели и алгоритмы: кластерный анализ, метод опорных векторов, метод главных компонент и т.п.

Вид математической модели зависит как от природы реального объекта, так и от задач и методов исследования объекта, а также требуемой достоверности и точности решения этой задачи.

Описательные (descriptive) модели рассматривают влияние различных факторов или построению эмпирических моделей систем. Они уделяют внимание улучшению понимания анализируемых данных.

Предсказательные (predictive) модели используются для предсказания будущих результатов на основании исторических наборов данных. На первом этапе построения модели используют исторические наборы данных, далее модель используется для построения прогнозов.

В описательных задачах самое главное — это дать наглядное описание имеющихся скрытых закономерностей, в то время как в предсказательных задачах на первом плане стоит вопрос о предсказании для тех случаев, для которых данных еще нет.

Среди основных задач интеллектуального анализ данных кроме классификации, кластеризации, можно выделить прогнозирование, оценивания, анализа связей, визуализация [15].

Описательные методы:

- ☐ поиск ассоциативных правил;
- ☐ кластерный анализ;
- ☐ построение регрессионной модели.

Предсказательные методы:

- ☐ классификация объектов (для заранее заданных классов);
- ☐ регрессионный анализ, анализ временных рядов.

На некоторых из них остановимся подробнее.

Задачей **классификации** называют задачу обучения с учителем, в случае когда доступны данные, в которых уже выделены и известны классы, к которым они относятся. Эти данные можно использовать для обучения модели, а саму модель — после обучения на неразмеченных данных.

В случае если группы заранее не выделены и используемая модель дей-

ствуется согласно заранее заложенным в нее правилам, то такую задачу называют **кластеризацией**.

Цель кластеризации — поиск существующих структур.

Регрессионные модели описывают функциональные зависимости (линейные и нелинейные) между зависимыми и независимыми числовыми переменными. Существуют регрессионные модели которые описывают функциональную зависимость между категориальными переменными.

Задача поиска ассоциативных правил — нахождение зависимостей (ассоциаций) между объектами или событиями, которые могут быть представлены в виде правил, для лучшего понимания природы анализируемых данных и предсказания появления тех или иных событий;

Ассоциация — поиск закономерности между связанными событиями в наборе данных. Поиск закономерностей осуществляется не на основе свойств анализируемого объекта, а между несколькими событиями, которые происходят одновременно. (65 % купивших чипсы берут также и «колу», а при наличии скидки за такой комплект «колу» приобретают в 85 % случаев.)

Примером такой закономерности служит правило $X \Rightarrow Y$, указывающее, что из события X следует событие Y . Такие правила называются ассоциативными.

Правило последовательности: после события X через определенное время произойдет событие Y . Например, после покупки квартиры в 50% приобретается и новая мебель.

Прогнозирование — на основе исторических данных получить прогноз будущих значений. Построение трендов объекта или событий основано на анализе состояния в прошлом.

1.2. Типы данных

Многообразие источников данных, способов наблюдения, сбора, регистрации данных определяют их структурное и типовое многообразие. Данные могут быть представлены в различной форме. Уже на первом этапе подготовки данных полезно определить тип данных, который во многом уже подскажет методы их исследования.

Исходный массив данных представляет собой результаты наблюдений объектов и процессов исследования и факты, собранные из различных источников. наборы или массивы данных отличаются м по типу измерения для каждого наблюдения, по факту упорядоченности во времени, по особенностям сбора данных, по количеству признаков, описывающих объект

исследования, для которых информация собиралась, по задачам и целям сбора информации.

Количество признаков, порций информации под которые она собиралась определяет сложность массива данных, его структуру и размерность, что существенным образом влияет на выбор метода анализа.

По типу данные делятся на количественные и качественные, соответственно различают количественный и качественный анализ данных.

Количественные данные делятся на дискретные и непрерывные и непосредственно представляют измеренный или наблюдаемый объем некоторого признака или количество элементарных единиц.

Важно то, что количественные измерения используют для измерения количественные или интервальные шкалы, представляют количество чего-либо, отвечают на вопрос «сколько?» и к ним не относятся те измерения, которые используют процедуры кодирования.

Качественные данные представляют собой результаты измерений качественной характеристики признака, которым обладает объект. Существуют два типа качественных данных; качественные данные номинальные и качественные данные порядковые. Первому классу принадлежат данные, для измерения которых используется только процедура определения принадлежности одному из рассматриваемых классов. Соответствующая шкала измерения называется номинальной или классификационной. Второй класс представляет качественные данные, отличие которых состоит в том, что для их измерения вводится отношений порядка или отношение предпочтения. Поэтому такие данные называются порядковыми, категориальными или ординальными. Для качественных данных существуют существенные ограничения по выполнению вычислительных процедур.

Стоит отметить, что во многих практических задачах кроме количественных и качественных данных приходится сталкиваться с «многозначными данными», примерами которых могут служить: список значений, интервальные данные, более сложный тип модально-значные данные, в которых содержатся вероятности, веса, или другие связанные значения. Подобные данные попадают в класс данных, который называется «символьные данные».

В классической структуре данных с каждым индивидуумом (микроданные) связано одно численное значение или одна категория. Однако интерес многих исследований лежит в изучении групп записей, собранных в соответствии с характеристиками индивидов или классов индивидов, что приводит к макроданным. Классическое решение для этих ситуаций состоит

в том, чтобы связать с каждым человеком или классом людей центральную меру, например, среднее значение или другие соответствующие записи. Однако, с этой опцией изменчивость по записям теряется. Для таких ситуаций символьный анализ данных предлагает, чтобы распределение или интервал значений отдельных записей были связаны с каждой единицей, таким образом, рассмотрев новые типы переменных, называемые символьными переменными. Одним из таких типов символьных переменных является гистограммно-значная переменная, где каждому анализируемому объекту соответствует эмпирическое распределение, которое может быть представлено гистограммой или функцией квантиля. Если для всех наблюдений каждая единица принимает значения только на одном интервале с весом, равным единице, тогда значение гистограммно-значной переменной сводится к частному случаю интервально-значной переменной. В любом случае предполагается равномерное распределение в рассматриваемых интервалах. Соответственно, необходимо адаптировать понятия и методы классической статистики к новым видам переменных. Таким образом, структурное и типовое многообразие данных определяет выбор методов их представления, методов предобработки и обработки, моделирования и анализа.

1.3. Предобработка данных

Предобработка данных — важный этап интеллектуального анализа данных.

Процедуры предобработки данных включают в себя достаточно большой перечень методов, решающих проблему дублирования данных, восстановления пропусков в данных, исследование аномальных значений и многие другие задачи.

В этапе предобработки данных, мы рассматриваем проблему изучения внутренней структуры данных.

Для описания их изменчивости на основе применения соответствующих математических моделей представления эмпирической информации рассматриваются различные подходы к представлению данных. Одной из задач, которая требует предварительного изучения имеющейся информации, является задача восстановления зависимостей по эмпирическим данным. Для обоснования выбора математической модели и метода с целью последующих расчетов необходимо провести тщательное изучение особенностей данных и типов неопределенности, определяющих их полноту и достовер-

ность.

Предобработка включает ряд важных шагов и процедур, результаты выполнения которых существенным образом могут повлиять на качество исследования данных в целом.

Выбор данных

Перед началом анализа данных, следует определить и исследовать источники данных, исследовать структуру данных, проанализировать виды неопределенности, оценить их полноту. Например, оценить зашумленность данных.

В исследовании данных важной задачей является процесс выявления существующих закономерностей, взаимосвязей или их отсутствие, анализ неопределенностей и их источников, выбор методов и подходов, соответствующих поставленным задачам.

При решении задач анализа данных, особенно Big Data, наблюдается недостаток эффективных способов хранения данных.

Рассмотрим основные этапы работы с данными, которые можно условно отнести к процедурам предобработки данных.

Извлечь данные. Прежде чем данные анализировать, надо данные извлечь из различных источников (иногда иметь разрешение на использование данных). Проверить достоверность данных и т.п.

Подготовить данные. Подготовка данных важный этап в их анализе.

Проблемы подготовки:

- ☐ расшифровка данных;
 - ☐ проверка качества данных и устранение неполных или ошибочных данных;
 - ☐ перевод данных в нужную форму
- и т.д. и т.п.

Импорт данных. Данные необходимо импортировать в хранилище данных.

Для удобства анализа часто проводят процедуру агрегирования данных с целью сокращения объема.

Очистка данных.

Существует понятие «грязные» данные, которое включают в себя недостающие данные, неправильные данные и непригодные данные.

Существуют различные форматы представления данных, возникают дубликаты записей в разных форматах. В этом случае очистка данных основана проверке и повторным сборе данных.

Оценка качества данных. Можно выделить следующие атрибуты

качества данных: **точность, актуальность (своевременность), полнота, логичность.** Это направлено на необходимость обнаружению различных ошибок в имеющихся данных.

Можно выделить в процессе очистки данных важно установление типов ошибок, затем идентификация похожих ошибок, далее их исправление.

Существует подходы и эвристические правила, которые могут быть использованы для обнаружения и исправления данных.

Статистические методы. Используются методы вычислительной статистики для анализа данных и проверки гипотез.

Кластеризация. Подробно описаны во второй части пособия.

Правила ассоциации. Позволяют проверить данные на достоверность. Позволяет работать с данными разных типов.

Проблема недостающих значений. Важно при этом знать структуру недостающих данных и метазнания об информации, которую они содержат. Добавление недостающих знаний — проблема которую надо решать с осторожностью.

Возможные причины отсутствия значений:

- пропуски в базах данных;
- неисправность измерительной техники, ошибки измерений.

Способами решения:

- пропуск блоков информации;
- заполнение статистическими значимыми значениями;
- экспертные оценки;
- интерполяция, регрессия и использование кодов, исправляющие ошибки.

Уменьшение размерности данных. Для уменьшения размерности можно использовать метод главных компонент, что позволяет вводить комбинации атрибутов — главные компоненты. Подробно во второй части пособия.

Проблема селекции атрибутов часто носит комбинаторный характер. В этом случае она носит NP-hard характер, и число операций для ее решения растет по экспоненте от числа атрибутов.

Выбор оптимального числа атрибутов должен носить разумный характер и подобен выборы числа главных компонент.

Выделяют три класса алгоритмов выбора атрибутов:

ранжирование используются в вычислительной статистике путем вычисления оценки атрибута;

комбинации атрибутов путем генерации подмножеств;

методы отбраковки и упорядочения для проверки значимости атрибутов на точность моделей.

Существуют линейные и нелинейные методы уменьшения размерности. Как мы уже говорили одним из самых распространенных методов — метод главных компонент. Он осуществляет ортогональное преобразование исходной системы координат к главным компонентам. Существует его модификация в функциональном анализе данных — разложение Кархунева-Леве.

Можно выделить следующие методы нелинейных алгоритмов:

многомерное масштабирование осуществляется специальными методами проектирования (проекция Сэммона);

обучение на множествах, подход основан на различных отображениях множеств данных включая нелинейные расширения метода главных компонент;

нейронные сети используют самоорганизующиеся карты (SOM), сети Кохонена.

Обнаружение выбросов данных

Аномальные данные могут привести к ошибкам или существенно ухудшить познавательные свойства моделей.

Необходимо использовать методы детектирующие выбросы. Таких методов в настоящее время достаточно много. Один из самых простых способов — определить области допустимых значений. При этом стараются выявить механизм порождения выбросов.

Можно рассмотреть ряд методов основанных на обучении на множествах данных без аномалий. В тех случаях, когда невозможно обучение на данных без аномалий, используют статистические подходы. Считается, что аномальные данные встречается значительно реже.

При этом предполагают, что данные подчиняются определенному распределению. Таким образом, можно обнаружить данные лежащие вне распределений.

На похожих идеях основаны вероятностные подходы, основанные метрических свойствах аномальных значений.

Можно использовать различные типы регрессии в многомерных пространствах.

1.4. Современные методологии исследования данных

Методология интеллектуального анализа данных — это общая стратегия исследования, которая определяет способ проведения изучения данных методы, которые будут использоваться в нем. Эти методы, описанные в методологии, определяют средства или способы сбора и обработки данных, а иногда и то, как должен быть рассчитан конкретный результат. Методология не определяет конкретных методов, хотя большое внимание уделяется природе и видам процессов, которые должны соблюдаться в конкретной процедуре или для достижения цели. С помощью методов наука о данных добывает знания об изучаемом предмете, анализирует и обрабатывает полученные данные, включается в систему известных знаний. Полученные достоверные знания используются для построения научных теорий и выработки практических рекомендаций.

Цикл работы с данными по модели CRISP

CRISP — межотраслевой стандартный процесс для исследования данных) — это проверенная в промышленности и одна из наиболее распространенных методологии по интеллектуальному исследованию сырых данных. Методология исследования данных CRISP включает шесть этапов: понимание бизнеса, начальное изучение данных, подготовка данных, моделирование, оценка решения и внедрение. Поиск данных включает четыре этапа: формулировка запроса, консультации, самостоятельный поиск, запрос и получение данных. Хранить данные можно на твердых носителях, серверах или в облачных хранилищах. Обработка данных включает в себя: первичную обработку и очистку, выделение общих признаков, уплотнение данных, выбор модели для анализа. Анализ данных — совокупность действий исследователя, направленных на получение определенных представлений о характере явления, описываемых этими данными. Визуализация данных — процесс представления данных в агрегированном, понятном для восприятия человеком виде.

Ее развитием в условиях Big Data является модель CRISP-DM (CRoss Industry Standard Process for Data Mining). Этот проект был задуман в 1996 году, а в следующем году он был реализован как проект Европейского Союза в рамках инициативы финансирования ESPRIT. Проект возглавляли пять компаний: SPSS, Teradata, Daimler AG, NCR Corporation и OHRA (страховая компания). Проект был наконец включен в SPSS. Методология чрезвычайно детально ориентирована на то, как должен быть определен проект интеллектуального анализа данных.

Цикл работы с данными по модели CRISP — DM

Модель CRISP-DM или Cross-Industry Standard Process for Data Mining. Модель нацелена на исследование данных и является интерактивной,

Этап 1. Цели и план. Разработка целей и плана анализа данных включая критерии качества.

Этап 2. Понимание данных. Оценка взаимодействия данных и процессов, очистка данных и оценка достоверности.




Рис. 1.1. Модель CRISP

Этап 3. На этом этапе данные подготавливаются для дальнейшей работы: проверка, объединение, форматирование.

Этап 4. Построение модели данных, например на этом этапе можно построить регрессионные модели или случайные леса, кластерный анализ и др.

Этап 5. На этом этапе происходит оценка результатов моделирования, проверка решений и тестировании.

Этап 6. Рассматриваются результаты использования полученных результатов для решения поставленных задач.

Цикл работы с данными по методологии SEMMA

Подход SEMMA (Sample Explore Modify Model Assess) подразумевает, что все процессы выполняются в рамках гибкой оболочки, поддерживающей выполнение всех необходимых работ по обработке и анализу данных. Подход SEMMA сочетает структурированность процесса и логическую организацию инструментальных средств, поддерживающих выполнение каждого из шагов. Благодаря диаграммам процессов обработки данных, под-

ход SEMMA упрощает применение методов статистического исследования и визуализации, позволяет выбирать и преобразовывать наиболее значимые переменные, создавать модели с этими переменными, чтобы предсказать результаты, подтвердить точность модели и подготовить модель к развертыванию. Эта методология не навязывает каких-либо жестких правил. Разработчик может располагать научными методами построения концепции проекта, его реализации, а также оценки результатов проектирования.

Модель SEMMA состоит из нескольких этапов (рис. 1.2).




Рис. 1.2. Модель SEMMA

Этап 1 — извлечение данных для построения модели.

Этап 2 — изучение данных, поиск аномалий.

Этап 3 преобразование данных для создания модели.

Этап 4 — построение модели для нахождения искомого результата.

Этап 5 — оценка результатов, их полезности и адекватности.

1.5. Системы и платформы для интеллектуальной обработки данных

С развитием компьютеризации огромное количество данных начало стремительно накапливаться в электронном виде – в виде баз знаний, данных, репозиторий, каталогов и других сборников информации.

Объем накапливаемых в каждой компании данных растет с каждым днем, также увеличивается и стоимость управленческих ошибок, основанных на неверных или неполных данных. Потребность бизнеса в аналитике крайне высока.

Возникают проблемы с интеграцией, передачей данных и их согласованной обработкой. Часть информации может просто потеряться. Эти трудности решает такой класс продуктов, как программно-аналитические платформы.

В таких условиях даже самые мощные технологии анализа данных, как KNOWLEDGE DISCOVERY IN DATABASES (KDD) и DATA MINING не представляют особой ценности без инструментальной поддержки в виде соответствующего программного обеспечения.

Аналитическая платформа — это специализированное программное решение (или набор решений), которое содержит в себе все инструменты для осуществления процесса извлечения закономерностей из «сырых» данных: средства консолидации информации в едином источнике (хранилище данных), извлечение, преобразование, трансформацию данных, алгоритмы DATA MINING, средства визуализации распространения результатов среди пользователей, а также возможности «конвейерной» обработки новых данных.

Поэтому в аналитической платформе, как правило, всегда присутствуют гибкие и развитые средства консолидации, включающие богатые интеграционные механизмы с промышленными источниками данных, инструменты очистки и преобразования структурированных данных и их последующее хранение в едином источнике в специальном многомерном виде — в хранилище данных. Модели, описывающие выявленные закономерности и правила, прогнозы также хранятся в специальном источнике данных — репозитории моделей.

Аналитическая платформа интеллектуальной обработки данных (или в упрощенном варианте дата-платформа) — это программный комплекс для интеллектуального анализа данных, позволяющий эффективно обрабатывать, анализировать и визуализировать информацию для обеспечения процесса принятия решений в различных областях деятельности.

В качестве примера приведем программный продукт Форсайт. Аналитическая платформа (англ. Foresight. Analytics Platform) от компании Форсайт предназначен для бизнес-аналитики и анализа данных. Система построена на методах классической и продвинутой аналитики.

Платформа полностью обеспечивает заказчика всеми инструментами для сбора, обработки, мониторинга, анализа данных, решения задач предиктивной аналитики, автоматизации процессов. Включает весь арсенал актуальных технологий: машинное обучение, большие данные, алгоритмы искусственного интеллекта, построение прогнозных и оптимизацион-

ных моделей.

«Форсайт. Аналитическая платформа» позволяет заказчику значительно сократить сроки разработки, а также обеспечить доработку с минимальным объемом программирования. На базе платформы разработано большое количество прикладных решений: продукты для управления бюджетированием, управления инвестиционными программами и проектами, консолидации отчетности, кредитный конвейер (решение для банковского сектора), ситуационные центры, решения для оптимизации производственной деятельности, предиктивного обслуживания, управления проверками, управления рисками, мобильный склад, голосовой помощник и многие другие.

Платформа отличается высокой производительностью, масштабируемостью, поддерживает разнообразные типы данных и их источников, имеет универсальную функциональность и широкие возможности для интеграции с различными российскими и зарубежными системами, обеспечивает поддержку российских ОС и СУБД, а также гарантирует высокую степень информационной безопасности.

Блок продвинутой аналитики «Форсайт. Аналитической платформы» обеспечивает возможность визуального конструирования моделей и алгоритмов любой сложности для эконометрических, оптимизационных и прогнозных расчетов, поддерживает решение актуальных для прогнозирования задач «Что будет, если...?» и «Что необходимо для...?». Аналитики могут использовать инструмент многовариантного сценарного моделирования, с использованием известных библиотек математических и статистических алгоритмов.

В рамках платформы доступно более 300 методов построения моделей, реализована интеграция с библиотеками R и Python. Это означает, что пользователь платформы может использовать в своих расчетах любую статистическую функцию, реализованную в мире на сегодняшний день. В рамках модуля «Временные ряды» реализовано огромное число алгоритмов, которые позволяют строить прогнозные модели для временных рядов. Также в рамках платформы доступны инструменты Data Mining и Machine Learning, есть возможность подключения к источникам Big Data и их обработки с помощью механизма In-Memory.

«Форсайт. Аналитическая платформа» включена в Единый реестр российских программ для электронных вычислительных машин и баз данных. и является low-cod ориентированной.

В целом, дата-платформа — это набор интегрированных между собой

инструментов, которые позволяют компаниям делать регулярную и воспроизводимую аналитику данных.

Набор инструментов может быть разнообразным, но вкладываются они примерно в один и тот же алгоритм работы с данными:

- Источники. Весь набор источников данных — от простых файлов и реляционных БД до SaaS-решений, собирающих какую-либо потенциально полезную для бизнеса информацию.

- Обработка и трансформация данных. Здесь в работу вступают ETL-или ELT-инструменты. Данные забираются из источника, подвергаются преобразованиям, если это необходимо, и направляются в хранилище. Здесь могут быть задействованы такие инструменты, как Apache Spark, Kafka, Airflow.

- Хранение данных в формате, подходящем для дальнейшей работы с ними. Самыми популярными для этого являются Greenplum, Clickhouse, Vertica, инструменты из экосистемы Hadoop. Например, Greenplum — аналитическая колоночная массивно-параллельная СУБД, разработанная для хранения и обработки больших объёмов информации. Она позволяет работать с терабайтами и даже петабайтами данных. Greenplum нужна тем, у кого данных больше, чем очень много, то есть для работы с большими данными. Кроме того, хранить данные — часть дела. Если к записям нельзя обращаться за адекватное время и выполнять над ними нужные операции — толку от таких данных нет. Поэтому Greenplum нужна тем, кто не только хранит огромные объёмы информации, но и активно с ними работает. Конечно, проблемы работы с большими объёмами появились не вчера, инструменты под эти задачи на рынке есть: ClickHouse, Cassandra и другие. Но после чтения документации можно заметить, что несмотря на общую сферу применения, у Greenplum есть особенности, которые четко определяют, когда точно нужна эта система, а когда стоит выбрать другую.

- Непосредственно анализ данных — описательный и/или предсказательный. В качестве инструмента тут может использоваться SQL, Python или любые другие языки. — Вывод/визуализация данных для конечных пользователей. Чаще всего какая-то принятая в компании BI-система (Power BI, Qlik, Tableau, Apache Superset или их аналоги).

Это грубое деление на этапы работы, которые охватывает платформа для обработки данных. Архитектура конкретного решения может быть более сложной.

Платформы, как правило, предоставляют возможность обрабатывать как структурированные, так и неструктурированные данные из множества

источников. Платформы анализа больших данных — это уже инструмент для прогностического и динамического анализа. Так как предиктивный анализ связан нацелен на прогнозирование какого-то параметра или события, то он фокусируется на конкретной задаче, в отличие от business intelligence. Дескриптивный же анализ должен позволять пользователям гибко создавать отчет в том разрезе, который им потребуется.

Аналитические платформы развиваются по нескольким ключевым направлениям: — подготовка и обработка данных, включая, например, такие вопросы, как очистка и консолидация данных;

— создание и внедрение программного обеспечения на основе методов компьютерного и математического моделирования, современных технологий интеллектуального анализа данных, включая машинное обучение, нейронные сети;

— методы и технологии визуализации.

При этом каждое направление само по себе оставляет нерешенным ряд вопросов. В частности, визуализация не решает сложных задач по консолидации и очистке данных, проведению сложных расчетов, прогнозированию и оптимизации.

Машинное обучение не работает, когда недостаточно данных, нет фиксации влияющих факторов, необходимо учесть бизнес-правила, а данные забиты «шумом».

Также аналитики сталкиваются с такими вызовами, как растущее количество источников, отсутствие связности между данными и унификации, разная структура и детализация данных.

На рынке программно-аналитических платформ, важное место занимает Loginom Company (ранее была известна как BaseGroup Labs) — профессиональный разработчик продуктов и решений в области анализа данных. Компания специализируется на разработке систем для глубокого анализа данных, охватывающих вопросы сбора, интеграции, очистки данных, построения моделей и визуализации. Помогает внедрять инновации, принимать более обоснованные и правильные управленческие решения для увеличения прибыли, снижения затрат и предотвращения рисков как коммерческим, так и государственным компаниям. Новая аналитическая платформа Loginom, пришедшая на смену платформе предыдущего поколения Deductor, разрабатывалась на протяжении 7 лет. Декларируемые цели и задачи потребовали не просто обновления Deductor, а построения системы на базе принципиально новой архитектуры. В результате специалисты BasegroupLabs создали продукт, максимально адаптированный к потреб-

ностям компаний малого и среднего бизнеса.

Компания разработала готовое решение со встроенными возможностями консолидации, очистки, сложных расчетов, прогнозирования и оптимизации данных. Пользователям Loginom доступны инструменты для самостоятельной настройки параметров анализа, смены правил и модификации процессов. В Loginom встроена очистка данных.

Платформа поддерживает веб-сервисы и мобильные приложения для работы с системой, обладает широким выбором возможностей для визуализации результатов. Быстрое развертывание платформы возможно на любой рабочей станции с минимальными требованиями к «железу».

Loginom эффективно утилизирует аппаратные ресурсы, способен работать на серверах минимальной конфигурации. Систему можно развернуть как в частном, так и в публичном облаке. Loginom радикально сокращает время от генерации идеи до практического применения аналитики в бизнесе.

Loginom — аналитическая low-code платформа, которая позволяет проводить анализ структурированных данных любого уровня сложности без программирования.

Объем обрабатываемых данных увеличился с 2 ГБ до 16 ТБ, скорость обработки данных увеличились примерно в 1000 раз по сравнению с предыдущей версией. Время установки новых решений сократилось с нескольких суток до 5 минут. По ряду показателей Loginom превосходит западные аналоги. Платформа Loginom призвана изменить правила игры, так как она позволяет использовать аналитический функционал без специальной подготовки, сделать глубокую аналитику доступным бизнес-инструментом. Аналитическая платформа Loginom включена в Единый реестр российских программ для электронных вычислительных машин и баз данных и является low-code ориентированной, что позволяет организациям создавать и развертывать пользовательские приложения без обширных знаний в области программирования. Платформы с низким уровнем кода предназначены для упрощения процесса разработки приложений и делают его более доступным для более широкого круга пользователей, включая бизнес-аналитиков, экспертов в предметной области и других не технических заинтересованных сторон. Low-code называют метод разработки, при котором к программированию «вручную» прибегают минимально. Вместо кода для моделирования приложений используются визуальные конструкторы, а для решения типовых задач — готовые скрипты. Главную ценность составляет возможность обойтись без программистов, когда нужно создать

или изменить какое-то приложение, модуль или даже продукт. Для проведения необходимых работ компетенций администратора платформы будет более чем достаточно. Low-code платформы привлекательны, поскольку обладают свойством гибкости в настройках, а на разработку требуют меньше времени. Такие платформы должны уметь интегрироваться с широким набором систем, а также позволять добавлять новые функции в любое приложение. Платформа позволяет не просто создать какое-то отдельное приложение без программирования для какой-то бизнес-задачи (например, согласование пропуска), но вся разработка встроится в единую систему управления процессами предприятий. Все формы, справочники и действия будут иметь ее свойства — контроль прав, доступ к общим справочникам, типовые возможности интерфейса и поиска. При этом для реализации сложных задач с большим количеством переменных используется классическое программирование.

Укажем основные возможности и задачи, которые успешно решает Loginom: — извлечение преобразование загрузка (ETL); — оперативная аналитическая обработка данных; — система принятия решений; — рабочее пространство аналитика; — инструмент машинного обучения; — качество данных; — глубинный анализ процессов. Для оптимизации повседневной работы аналитиков были сформированы библиотеки Loginom Kits — наборы компонентов и подмоделей для реализации прикладных бизнес-задач, эталонно спроектированные экспертами Loginom Company:

1.6. Вопросы для самоконтроля

1. Какие задачи работы с данными вам известны?
2. Верно ли то, что чем больше данных, тем более точную модель мы получим?
3. Перечислите основные проблемы, с которыми может столкнуться аналитик при работе с «грязными» данными.
4. Раскройте понятие «проклятие размерности».
5. Для каких целей используются модели CRISP и SEMMA?
6. Если для анализа данных вам требуется значение возраста, а вы имеете данные о дате рождения, то опишите, каким образом вы будете получать новый вычисляемый показатель, и для чего он может быть более удобным.
7. Если вам задана последовательность данных), и вы предполагаете, что среди данных есть ошибочное значение, то какое из приведенных значений вы идентифицируете как неверное и почему?

8. Раскройте содержание понятия «интеллектуальная обработка данных».
9. Укажите основные предпосылки возникновения программно-аналитических платформ.
10. Какие задачи призваны решать дата-платформы.
11. Проанализируйте возможности программно-аналитической платформы Loginom.
12. Проанализируйте возможности «Форсайт. Аналитическая платформа».

Глава 2

Математические методы для аналитики данных

2.1. Кластеризация и классификация

Задачей **классификации** называют задачу обучения с учителем, в случае когда доступны данные, в которых уже выделены и известны классы, к которым они относятся. Эти данные можно использовать для обучения модели, а саму модель — после обучения на неразмеченных данных.

В случае если группы заранее не выделены и используемая модель действует согласно заранее заложенным в нее правилам, то такую задачу называют **кластеризацией**.

Между двумя рассмотренными классами методов (обучение с учителем и обучение без учителя) находится класс методов **полуконтролируемого обучения**. Полуконтролируемое обучение (обучение с частичным привлечением учителя) представляет собой подход, заполняющий пробел между неконтролируемым обучением и обучением с учителем (рис. 2.1).

Данную область можно разбить на методы полу контролируемой классификации и методы полуконтролируемой кластеризации. Процесс работы алгоритмов полуконтролируемой классификации начинается с контролируемого обучения и выработки идеи, каким образом использовать неразмеченные данные в обучающем процессе; полуконтролируемая кластеризация начинается с полуконтролируемого обучения и интегрирует размеченные данные в процесс кластеризации.

Возникновение данной группы методов связано с тем, что неразмеченные данные обычно получить проще и дешевле (много таких данных имеется в свободном доступе), но наряду с этим они предоставляют меньше информации, чем размеченные данные (их получение связано с большим объемом экспертной работы). При этом при совместном использовании раз-




Рис. 2.1. Виды обучения в задачах структурирования данных

меченных и немеченных данных можно получить лучшие результаты и сэкономить ресурсы.




Рис. 2.2. (часть 1 из 2) Отличия в постановках задач структурирования данных

Визуально разница между задачами классификации, полуконтролируемой классификации, полуконтролируемой кластеризации и кластеризации представлена на рис. 2.1 (переменные с индексом l — тренировочные данные, переменные с индексом u — будущие данные, с которыми будет работать алгоритм) [17].

□ **Классификация:** $C_u = \emptyset$, T_l — обучающие данные, X_u — будущие данные или не отнесенные к какому-либо классу (рис. 2.2, а). Решается

задача объяснения преобразований между X_l и C_l , для дальнейшего использования на будущих сущностях (предсказание).

□ **Полуконтролируемая классификация:** $C_u = \emptyset$, $X_u \neq \emptyset$ — доступно и используется для обучения (рис. 2.2, б).

Решаются задачи:

- объяснения преобразований между X_l и C_l ;
- распределения по классам неструктурированных сущностей.




Рис. 2.3. (часть 2 из 2) Отличия в постановках задач структурирования данных

□ **Полуконтролируемая кластеризация:** $C_l \neq \emptyset$, $C_l \subseteq C$, $X_l \neq \emptyset$, $X_u \neq \emptyset$ (рис. 2.3, в). Решается задача структурирования данных. Для этого используется информация о структурированных сущностях как ограничение структурирования для еще неструктурированных сущностей.

□ **Кластеризация:** $C_l = \emptyset$, $C_u = \emptyset$ (рис. 2.3, г). Решается задача структурирования данных по заданным правилам. Доступны только неструктурированные сущности.

Кроме деления задач классификации и кластеризации по работе с данными все задачи разделяют на бинарные или двоичные (в задаче присутствуют только две группы объектов) и мультиклассовые (когда различающихся групп объектов в задаче более двух).

2.2. Метод опорных векторов (SVM)

Метод опорных векторов (англ. support vector machine, SVM) — один из наиболее популярных методов обучения, который применяется для реше-

ния задач классификации и регрессии. Основная идея метода заключается в построении гиперплоскости, разделяющей объекты выборки оптимальным способом. Алгоритм работает в предположении, что чем больше расстояние (зазор) между разделяющей гиперплоскостью и объектами разделяемых классов, тем меньше будет средняя ошибка классификатора.

Из всех типов моделей, описанных в этой главе, машины опорных векторов (SVM), пожалуй, самые загадочные. Они имеют много общего с нейронными сетями, но их довольно сложно объяснить, не прибегая к необходимой математике.

Говоря о классификации поведения людей, например о реакции на маркетинговую коммуникацию (событие) или об отсутствии реакции (несобытие), один из способов представить это так: события и несобытия — это разные предметы, разбросанные по столу. Кто-то стоял на одном конце стола и перебрасывал события на этот конец, а кто-то другой перебрасывал на стол не-события с другого конца. Большинство событий/несобытий остаются ближе к концу, откуда они были разбросаны, но в середине есть некоторое совпадение, и одно или два могут даже достичь другого конца. Ваша задача — провести линию, в результате которой по одну сторону от линии окажется как можно больше событий, а по другую — как можно больше несобытий. Два примера этого показаны на рис. 2.4.




Рис. 2.4

На рис. 2.4(а) показана наилучшая прямая линия, разделяющая две группы. Если вы измерите расстояние между каждой точкой и линией, то суммируете эти расстояния, сумма будет максимальной, какой она может быть. Говорят, что линия «максимизирует маржу». Можно было провести линию и в других местах, но сумма расстояний была бы меньше — запас не был бы максимальным. На практике это означало бы получение больше-

го количества случаев не на той стороне линии. Концептуально линейные модели аналогичны прямой линии на рис. 2.4(a). На рис. 2.4(b) ту же работу выполняет волнистая линия, но поскольку линия не ограничена прямой линией, она лучше разделяет две группы. Нелинейный метод, такой как нейронная сеть, концептуально больше похож на этот пример, и именно поэтому теоретически нейронные сети и машины опорных векторов превосходят линейные модели.

Один из распространенных примеров — медицинский диагноз. Сложность постановки медицинского диагноза в наличии большого числа симптомов. Для построения правильных алгоритмов определения заболевания необходимо использовать исторический опыт диагностики. Нам необходимо правильно разделить пациентов на здоровых и больных.

Многие заболевания безусловно можно распознать с помощью дорогих анализов и методик. Например, сердечно-сосудистые заболевания (ССЗ) эффективно определяются с помощью компьютерной томографии. Подход основанный на данных — использование более дешевых физиологических симптомов: частота пульса под нагрузкой.

Используя эти данные можно построить модель рис. (2.5). Подобные модели, позволяют с достаточной степенью уверенности предсказывать состояние пациентов.




Рис. 2.5. Разделение множества пациентов

На рис. (2.5) темная область — здоровые пациенты, а светлая — больным. Здоровые пациенты отображены светлыми точками, больные — тем-

ными.

Главная задача метода — построение границы, разделяющей два множества.




Рис. 2.6. Способы разделить множества

Для этих целей надо находить элементы из разных множеств, которые наиболее близки. Граница проводится между этими элементами — опорными векторами рис. (2.7).




Рис. 2.7. Граница между множествами

Это довольно быстрый метод, поскольку, в отличие от регрессии использует только найденные элементы. Однако это делает метод неустойчивым и чувствительным к выбору элементов. Можно понизить чувствительность метода и построить более гибкие границы, допуская определенный уровень ошибок.

Дальнейшее развитие метода опорных векторов состоит в использовании ядерных функций. Это позволяет строить криволинейные границы

между множествами в пространствах более высоких размерностей.




Рис. 2.8. Использование пространств более высоких размерностей

Отобразив данные с помощью ядерных функций в пространства более высоких размерностей можно разделить множества с помощью гиперплоскости.

На рис. (2.8) темные точки отделены от светлых на двумерной плоскости с помощью плоскости в трех мерном пространстве.

Эти возможности обеспечивают применение метода для решений большого числа прикладных задач.

Математическое описание задачи

Пусть элементы имеют вид:

$$\{(\mathbf{x}_1, c_1), (\mathbf{x}_2, c_2), \dots, (\mathbf{x}_n, c_n)\}$$

где $c_i \in \{-1, 1\}$, $\mathbf{x}_i \in R^p$.

В этой обучающей выборке значения $\{-1, 1\}$ определяют различные классы. Следуя методу мы строим разделяющую гиперплоскость, которая имеет вид:

$$(\mathbf{w}, \mathbf{x}) - - - b = 0,$$

где $\mathbf{w}$ — нормаль к гиперплоскости. и

$$\frac{b}{\|\mathbf{w}\|}$$

расстояние до гиперплоскости от начала координат.

Мы ищем оптимальное разделение и гиперплоскости могут быть представлены в виде

$$(\mathbf{w}, \mathbf{x}) - - - b = 1,$$

$$(\mathbf{w}, \mathbf{x}) - - - b = -1.$$

В случае линейной разделимости, можно выбрать гиперплоскости таким образом, чтобы между ними было максимальное расстояние, при этом необходимо проверить, что для всех i

$$c_i((\mathbf{w}, \mathbf{x}_i) - b) \geq 1, \quad 1 \leq i \leq n.$$

Построение разделяющей гиперплоскости сводится к решению следующей задачи

$$\begin{cases} \|\mathbf{w}\|^2 \rightarrow \min \\ c_i(\mathbf{w} \cdot \mathbf{x}_i - b) \geq 1, \quad 1 \leq i \leq n. \end{cases}$$

Ядра

Способ нелинейного классификатора основан на переходе от скалярных произведений к их обобщениям. В этом случае используются ядра, где каждое скалярное произведение заменяется ядерными функциями. Это позволяет строить нелинейные классификаторы.

Существующие ограничения

- Малые наборы данных отрицательно влияют на точность метода.
- Метод рассчитан на построение разбиения множества только на две группы.
- По существу метод строит покрытие множества двумя группами, т.е. они могут пересекаться и весьма существенно.

Краткие итоги

- ★ Метод опорных векторов множество данных на два подмножества, проводя границу между *опорными векторами*).
- ★ Существенное продвижение метода в использовании ядерных функций для более точного отображения x границ.
- ★ Он используется в Big Data, для классификации по двум группам.

Как и нейронные сети, машины опорных векторов — это нелинейный метод — в нашей непрофессиональной терминологии они также используют волнистую линию для разделения двух типов поведения. Однако машины опорных векторов подходят к проблеме немного иначе, чем алгоритмы нейронных сетей. Машина опорных векторов работает, чтобы найти уравнение линии, которая максимизирует запас, и уравнение этой линии является вашей моделью. Таким образом, оценка является мерой того, насколько вероятно событие лежит по обе стороны от линии (высокая оценка = вероятно событие, низкая оценка, вероятно, не событие). Звучит достаточно просто,

но в ситуациях, подобных рисунку 6.7(b), необходимо применить преобразования, прежде чем можно будет найти уравнение линии, которое максимизирует запас. На практике эти преобразования сложны, и структура модели машины с опорными векторами не поддается осмысленной интерпретации: вы не можете описать результаты в терминах: эта переменная дает столько-то очков, эта переменная столько-то очков и т. д. на.

При построении большинства типов прогностических моделей, включая линейные модели, деревья решений и нейронные сети, для построения модели используются все данные из выборки для разработки. В машине опорных векторов используются только те случаи, которые находятся ближе всего к прямой. Это «векторы поддержки». Если подумать, в этом есть смысл. Случаи, находящиеся далеко от поля (у края таблицы, откуда были разбросаны события), мало что скажут вам о том, где следует провести черту. Только случаи, расположенные ближе к середине таблицы, окажут существенное влияние на процесс классификации и, следовательно, будут включены в процесс моделирования (это кружки и крестики, выделенные жирным шрифтом на рис. 6.7). Ключевой частью алгоритма SVM является определение того, какие случаи в выборке являются опорными векторами, прежде чем применять подходящее преобразование к этим случаям, а затем использовать их для построения модели.

2.3. Кластеризация методом k-средних

Метод k-средних (англ. k-means) — наиболее популярный метод кластеризации. Был изобретён в 1950-х годах математиком Гуго Штейнгаузом[1] и почти одновременно Стюартом Ллойдом[2]. Особую популярность приобрёл после работы Маккуина[3].

Действие алгоритма таково, что он стремится минимизировать суммарное квадратичное отклонение точек кластеров от центров этих кластеров:

$$V = \sum_{i=1}^k \sum_{x \in S_i} \rho(x, \mu_i)^2$$

где k — число кластеров, S_i — полученные кластеры, $i = 1, 2, \dots, k$, а μ_i — центры масс всех векторов x из кластера S_i .

Пример. Кластеризация методом k-средних

Для построения кластеризации методом k-средних, некоторого набора данных, например, группы людей, необходима разнообразная информация об элементах данных. Относительно покупателей супермаркетов нам надо знать их доход. Люди с высоким доходом покупают более дорогие товары или тратят больше денег на питание.

Рассмотрим множество кинозрителей, их можно разбить на два кластера.




Рис. 2.9. Кластеры зрителей кинотеатров

На рис. 2.9 *Светлый кластер*: добросовестные экстраверты, которым нравятся боевики и романтические фильмы. *Темный кластер*: эмоциональные и открытые люди, которым нравится авангардное кино и фэнтези.

Число кластеров. Как определить число кластеров. Это выбор не однозначен. На рис. 2.9 изображено только два кластера, хотя можно представить кластеры поменьше. Число кластеров должно быть достаточным для выявления закономерностей и анализа данных. Но кластеры должны содержать отчетливые различия свойств данных.

Используя рис. 2.10 можно определить уровень разнообразия внутри кластеров. При увеличении числа кластеров разнообразие элементов уменьшается.

Изгиб на рис. 2.10, показывает разумное число кластеров.

Операция подобия Кластеризация представляет из себя бинарную операцию эквивалентности, которая порождает разбиение на классы эквивалентности. Мы считаем, что кластер содержит в чем-то эквивалентные




Рис. 2.10. График каменной осыпи

(похожие) элементы данных, их схожесть можно оценить используя специальные метрики или расстояния от центра кластера. Поэтому элементы кластера всегда должны быть ближе только к своему центру.




Рис. 2.11. Итеративный процесс

На рис. 2.11 показан итеративный процесс построения кластеров.

- 0: выбираем центры кластеров исходя из предпочтений.
- 1: вычисляем расстояния и разбиваем на кластеры.
- 2: находим центры кластеров.
- 3: разбиваем на кластеры (1) и находим центры кластеров (2) пока процесс не стабилизируется.

Ограничения

Поскольку мы строим разбиение множества, каждый элемент принадлежит только одному кластеру.

Кластеры сферичны относительно метрики. Поскольку мы используем метрические свойства, кластеры должны быть сферичны относительно метрики.

Разбиение. Метод k -средних не допускает пересечения кластеров.

Краткие итоги

Число этих кластеров k должно быть указано заранее. Кластеризация методом k -средних — метрический алгоритм, способ сгруппировать близкие по расстоянию элементы.

Процесс формирования кластеров итерационный.

Кластеры должны образовывать не пересекающиеся сферы относительно выбранной метрики.

2.4. Кластеризация методом k -NN

k -NN(*k-nearest neighbors algorithm*) — метрический алгоритм для автоматической классификации объектов или регрессии.

В случае использования метода для классификации объект присваивается тому классу, который является наиболее распространённым среди k соседей данного элемента, классы которых уже известны.

Алгоритм может быть применен к выборкам с большим количеством атрибутов (многомерным). Для этого перед применением нужно определить функцию расстояния; классический вариант такой функции — евклидова метрика.

Задача классификации в машинном обучении — это задача отнесения объекта к одному из заранее определенных классов на основании его формализованных признаков. Каждый из объектов в этой задаче представляется в виде вектора в N -мерном пространстве, каждое измерение в котором представляет собой описание одного из признаков объекта.

Допустим нам нужно классифицировать мониторы: измерениями в нашем пространстве параметров будут

- ★ величина диагонали в дюймах,
- ★ соотношение сторон,
- ★ максимальное разрешение,
- ★ наличие HDMI-интерфейса,
- ★ стоимость и др.

Случай классификации текстов несколько сложнее, для них обычно используется матрица термин-документ. Для обучения классификатора необходимо иметь набор объектов, для которых заранее определены классы. Это множество называется обучающей выборкой, её разметка производится вручную, с привлечением специалистов в исследуемой области.

Пример классификации k -ближайших соседей.




Рис. 2.12. Пример классификации k -ближайших соседей

На рис. 2.12 тестовый образец (зелёный круг) должен быть классифицирован как синий квадрат (класс 1) или как красный треугольник (класс 2). Если $k = 3$, то он классифицируется как 2-й класс, потому что внутри меньшего круга 2 треугольника и только 1 квадрат. Если $k = 5$, то он будет классифицирован как 1-й класс (3 квадрата против 2 треугольников внутри большего круга)

Алгоритм

Для классификации каждого из объектов тестовой выборки необходимо последовательно выполнить следующие операции:

- Вычислить расстояние до каждого из объектов обучающей выборки
- Отобрать k объектов обучающей выборки, расстояние до которых минимально
- Класс классифицируемого объекта — это класс, наиболее часто встречающийся среди k ближайших соседей

Нормализация. Разные атрибуты могут иметь разный диапазон представленных значений в выборке (например атрибут А представлен в диапазоне от 0.1 до 0,5, а атрибут Б представлен в диапазоне от 1000 до 5000), то значения дистанции могут сильно зависеть от атрибутов с большими диа-

пазонами. Поэтому данные обычно подлежат нормализации. При кластерном анализе есть два основных способа нормализации данных: минимакс-нормализация и Z-нормализация.

Минимакс-нормализация осуществляется следующим образом:

$$x' = (x - \min[X]) / (\max[X] - \min[X])$$

в этом случае все значения будут лежать в диапазоне от 0 до 1; дискретные бинарные значения определяются как 0 и 1.

Z-нормализация:

$$x' = (x - M[X]) / \sigma[X],$$

где σ — среднеквадратичное отклонение; в этом случае большинство значений попадёт в диапазон $(-3\sigma; 3\sigma)$.

Выделение значимых атрибутов. Некоторые значимые атрибуты могут быть важнее остальных, поэтому для каждого атрибута может быть задан в соответствие определённый вес (например вычисленный с помощью тестовой выборки и оптимизации ошибки отклонения). Таким образом, каждому атрибуту k будет задан в соответствие вес z_k , так что значение атрибута будет попадать в диапазон $[0; z_k \max(k)]$ (для нормализованных значений по минимакс-методу). Например, если атрибуту присвоен вес 2,7, то его нормализованно-взвешенное значение будет лежать в диапазоне

Взвешенный способ. При взвешенном способе во внимание принимается не только количество попавших в область определённых классов, но и их удалённость от нового значения.

Для каждого класса j определяется оценка близости:

$$Q_j = \sum_{i=1}^n \frac{1}{d(x, a_i)^2},$$

где $d(x, a_i)$ — расстояние от нового значения x до объекта a_i .

2.5. Деревья решений

Деревья решений, вероятно, являются вторым по популярности типом прогностической модели, используемой сегодня. Ключевыми особенностями деревьев решений являются: Модель создается путем сегментации населения на все более мелкие сегменты. Модель может быть представлена в виде «Древовидной диаграммы». Оценка модели определяется конечным узлом, в который попадает наблюдение после прохождения через дерево.




Рис. 2.13. Дерево решений. Спасение с тонущего “Титаника”

Пример: спасение с тонущего “Титаника”

Деревья решений позволяют получать решения исходя из ответов на которые на ответить да или нет. Поскольку дерево решений — бинарное дерево, т.е. ориентированный граф без циклов. Начало дерева — корень из которого исходит две ветви, которые являются деревьями. Выбор ветви — ответ на вопрос: да или нет. Процесс решения заканчивается листом, который и есть ответ на вопрос.

Бинарные деревья используются для хранения и извлечения информации. Деревья решений можно использовать для диагностике заболеваний, анализ поведения персонала, обнаружение злонамеренных действий. Деревья решений позволяют хранить различные типы переменных: как категориальные (большие и маленькие) так и непрерывные.




Рис. 2.14. Дерево решений

Бинарные деревья используют только два типа вопросов, если нужно можно организовать деревья, где из каждого узла исходит больше ветвей.

Построение дерева. Деревья решений строятся рекурсивно. Посколь-




Рис. 2.15. Множественные категории

ку каждое поддереву снова бинарное дерево, то для построения дерева решений необходимо разделить исходные данные на две группы так, что для каждой группы был однозначный ответ: да или нет. Далее этот процесс продолжается рекурсивно.

В результате рекурсии мы стараемся делить данные на две примерно равные части.




Рис. 2.16. Разделение данных

Разделение элементов данных на дереве решений и визуализация в виде диаграммы рассеяния

Рекурсивное построение.

(1): найти признак по которому данные можно разделить на две группы.

(2): повторять 1 для каждого поддереву, пока критерий остановки рекурсии не будет достигнут.

Варианты остановки рекурсии:

★ остановиться, когда элементы данных на каждом поддереву содержат

одно значение;

★ остановиться, когда на поддереве осталось менее пяти элементов данных.

Ограничения

★ *Нестабильность*. Поскольку деревья решений нестабильны, небольшое изменение данных может привести к изменению вида дерева.

★ *Неточность*. Использование признаков для разбиения на группы данных не всегда дает точный ответ.

На рис. 2.17 показан еще один пример дерева решений, на этот раз для прогнозирования еженедельных расходов домохозяйства на продукты (дерево регрессии).




Рис. 2.17. Разделение элементов данных на дереве решений

На рис. 2.17 свойства дерева решений показаны для выборки из 100 000 семей, чьи недельные расходы уже известны. Узел в верхней части дерева показывает средние семейные расходы для всех 100 000 случаев до применения какой-либо сегментации, т. е. 411 долларов США. Дерево «растет» сверху вниз. Каждое разделение в дереве определяется с помощью переменных-предикторов, которые, по определению алгоритма дерева решений, лучше всего различают разные значения расходов.

Для этого дерева алгоритм сегментации решил, что лучший вариант — начать с разделения населения на пять групп в зависимости от размера

семьи — и вы можете увидеть на диаграмме количество семей в каждой группе и средние расходы этих семей. Затем процесс деления снова применяется к каждому из полученных сегментов. Для одиноких людей (семья размером один) население делится на два дополнительных сегмента в зависимости от их доходов. Затем алгоритм решает, что дальнейшие разбиения не требуются. Итак, мы говорим о том, что люди, которые живут одни и чей ежемесячный чистый доход составляет менее 3750 долларов, свидетельствуют о том, что эти люди тратят в среднем 98 долларов в неделю на продукты. Точно так же для одиноких людей с доходом более 3750 долларов средний расход на продукты составляет 229 долларов.

Решения о том, как обращаться с кем-то, основаны на свойствах конечного узла, в который они попадают (конечные узлы выделены и пронумерованы на рис. 6.4). Хотя дерево не генерирует оценку как таковую, оценка для человека может быть принята равной:

Среднее значение обращений в этом узле. Например, для тех, кто находится в конечном узле 12, средний расход составляет 854 доллара. Когда мы хотим оценить семью, чьи расходы мы не знаем, если они попадают в конечный узел 12, мы прогнозируем, что их расходы составят 854 доллара.

Номер конечного узла (где конечные узлы пронумерованы в порядке средних расходов). Оценка составляет один, если семья попадает в конечный узел один, два, если они находятся в конечном узле два, и так далее.

В деревьях решений весов как таковых нет. Все основано на логике сегментации населения и знании того, как далеко можно зайти в процессе сегментации.

Существует множество алгоритмов, которые можно использовать для создания деревьев решений. Каждый алгоритм имеет определенные сильные и слабые стороны и использует несколько иную логику для выращивания дерева. Однако три наиболее часто используемых алгоритма для создания деревьев решений, которые вы найдете во многих пакетах статистического программного обеспечения, это: C4.5/C5.0,13 CART14 и CHAID.15.

Как и в случае с линейными моделями, замечательная особенность деревьев решений заключается в том, что их легко понять и объяснить нетехнической аудитории. Деревья решений также являются нелинейной формой модели. Это означает, что они могут представлять нелинейные отношения в данных без необходимости преобразования данных¹⁶. Если данные отсутствуют, это также можно использовать для определения сегментов без необходимости создания отдельных индикаторных переменных.

Краткие итоги

★ Дерево решений позволяет получить ответ на основании двоичных вопросов.

★ Для построения дерева используются *рекурсивное деление*. Он продолжается до наступления критерия останова.

★ Деревья решений подвержены процессу переобучения. Это может привести к перестройке дерева.

Расширение понятия дерева решений — *случайные леса*.

2.6. Случайные леса

Метод при котором вместо одного дерева решений строится множество различных деревьев решений. Для их построения используются случайные признаки разбиения на группы. Результаты прогнозов построенных деревьев (возможно неверных) обрабатываются для получения более точных результатов.

Хотя неверных ответов может быть достаточно много, правильный ответ может быть найден. Это связано с тем, что точные прогнозы коррелируют между собой, в то время как для ошибочных ответов этого нет. Способ повышения точности ответа известен как *ансамблирование*.

Пример: предсказание криминальной активности




Рис. 2.18. Тепловая карта частоты преступлений

На основе данных криминальной активности и погоды, был создан случайный лес деревьев решений. Используя исторические данные за несколько лет для получения случайного леса, его проверили на предсказания.

В результате проверки оказалось, что случайный лес давал более высокую точность чем отдельное дерево решений.

На рис. 2.20 показаны оценки преступности на четыре дня. На тепловой карте отчетливо видны участки на которые надо обратить внимание.




Рис. 2.19. Гистограмма точности прогнозов




Рис. 2.20. Прогнозы случайного леса на четыре дня подряд

Например, для четвертого дня было предсказана повышенная криминальная активность в серой зоне, которая в последствии подтвердилась.

Использование моделей прогнозирования показывает значимость пере-

менных в прогнозировании. На рис. 2.21, показано влияние на результаты прогноза: статистика преступлений, локация, дата и температуре.



Рис. 2.21. Главные переменные, участвовавшие в прогнозе

Ансамбли

Ансамблем называют модель, использующую предсказания других моделей, например, путем принципа голосования и тем самым повышающую точность прогноза.



Рис. 2.22. Принцип голосования

Ансамбль, (см. рис. 2.22) использующий принцип голосования, дает более точные результаты, чем отдельные модели. Это связано с корреляцией верных прогнозов между собой, в то время как ошибочные этого не делают.

Бэггинг. *Бэггинг* — это соединение бустрепа и агрегации. Бустреп для построения деревьев решений представляет случайную выборку из правил и данных. Это позволяет строить непохожие деревья, которые при этом в целом дают правильные предсказания.

На рис. 2.23 показано использование бустрепа для разбиения набора переменных случайным образом.




Рис. 2.23. Бэггинг

Модель случайного леса представляется *черным ящиком*, то ее внутреннее содержание не известно. Тем не менее, используя *бэггинг* можно получить более точные предсказания. Используя построение множества деревьев решений путем бутстрепа переменных, в то время как *принцип голосования* повышает точность прогнозов.

2.7. Метод главных компонент

Метод главных компонент *Principal Component Analysis* — это способ нахождения основополагающих переменных (известных как главные компоненты), которые дифференцируют ваши элементы данных оптимальным образом. Эти главные компоненты дают наибольший разброс данных.

Метод главных компонент один из основных способов уменьшить размерность данных, потеряв наименьшее количество информации. Изобретён Карлом Пирсоном в 1901 году. Применяется во многих областях, в том числе, в эконометрике, биоинформатике, обработке изображений, для сжатия данных, в общественных науках

Формальная постановка задачи. Задача анализа главных компонент имеет, как минимум, четыре базовых версии:

- аппроксимировать данные линейными многообразиями меньшей размерности;
- найти подпространства меньшей размерности, в ортогональной проекции на которые разброс данных (то есть среднее квадратичное отклонение от среднего значения) максимален;
- найти подпространства меньшей размерности, в ортогональной проекции на которые среднее квадратичное расстояние между точками максимально;
- для данной многомерной случайной величины построить такое орто-




Рис. 2.24. Пример главных компонент

гональное преобразование координат, в результате которого корреляции между отдельными координатами обратятся в нуль.

Аппроксимация данных линейными многообразиями.




Рис. 2.25. Иллюстрация к работе Пирсона

Иллюстрация к знаменитой работе Пирсона (1901): даны точки P_i на плоскости, p_i — расстояние от P_i до прямой AB . Ищется прямая AB , минимизирующая сумму $\sum_i p_i^2$

Векторы главных компонент могут быть найдены как решения однотипных задач оптимизации:

1. Централизуются данные (вычитанием среднего): $x_i := x_i - \bar{X}$.
Теперь

$$\sum_{i=1}^m x_i = 0.$$

2. Отыскивается первая главная компонента как решение задачи:

$$a_1 = \operatorname{argmin}_{\|a_1\|=1} \left(\sum_{i=1}^m \|x_i - a_1(a_1, x_i)\|^2 \right)$$

3. Из данных вычитается проекция на первую главную компоненту:

$$x_i := x_i - a_1(a_1, x_i);$$

Отыскивается вторая главная компонента как решение задачи:

$$a_2 = \operatorname{argmin}_{\|a_2\|=1} \left(\sum_{i=1}^m \|x_i - a_2(a_2, x_i)\|^2 \right).$$

Стандартизация — это преобразование переменных в единую шкалу.

Корреляции. Один из важных способов изучения данных — корреляционный анализ. Рассмотрим пищевые продукты, известна корреляция белков и жиров ($r = 0,56$), корреляция клетчатки и витамина С ($r = 0,57$). Таким образом, можно использовать комбинации показателей, уменьшая размерность. Поэтому метод главных компонент — инструмент *уменьшения размерности*.

Каждая главная компонента — это комбинация пищевых переменных, значение которой может быть положительным, отрицательным или близким к нулю.

Первая компоненту в пространстве показателей пищевых продуктов { (жир), (белок), (пищевые волокна), (Витамин С), } вектор с координатами:

$$PC_1 = (-0.45, 0.55, 0.55, 0.44).$$

$$PC_2 = (0.66, 0.21, 0.19, 0.79).$$

Выбор количества компонент. График рис. 2.28 показывает что большая часть информации о продуктах содержится в пространстве двух первых компонент, что соответствует *излому* на графике.

Таким образом, 70 % информации содержится в пространстве (PC_1, PC_2) .

	PC1	PC2	PC3	PC4
Жир	-0,45	0,66	0,58	0,18
Белок	0,55	0,21	-0,46	-0,67
Волокна	0,55	0,19	0,43	-0,69
Витамин С	0,44	0,70	-0,52	0,22

Рис. 2.26. Главные компоненты



Рис. 2.27. Продукты на плоскости (PC_1, PC_2)

Следует помнить, что МГК всегда формирует *ортогональные* главные компоненты, таким образом МГК — построение новой ортогональной системы координат, таким образом, что первые координаты содержат основную информацию.




Рис. 2.28. Распределение информации по компонентам

2.8. Ассоциативные правила

Анализ ассоциаций измеряет степень совпадения одного элемента с другим. Целью этого класса алгоритмов интеллектуального анализа данных является не прогнозирование появления элемента, как это делают классификация или регрессия, а поиск полезных закономерностей в совместном появлении элементов. Обучение правилам ассоциации — это ветвь процесса обучения без присмотра, которая обнаруживает скрытые закономерности в данных в форме легко распознаваемых правил.

Алгоритмы ассоциации широко используются в розничном анализе транзакций, системах рекомендаций и онлайн-анализе потока посещений веб-страниц. Одно из популярных применений этого метода называется анализом рыночной корзины, который выявляет совпадения одного розничного товара с другим товаром в рамках одной и той же сделки розничной покупки (Agrawal et al., 1993). Если закономерности в данных говорят нам, что детское питание и подгузники обычно покупаются вместе в одной транзакции, розничный торговец может воспользоваться этой связью для ценообразования в пакетах, размещения продуктов и даже оптимизации полочного пространства в планировке магазина. Аналогичным образом, в онлайн-бизнесе эта информация может быть использована для перекрестных продаж в реальном времени, рекомендаций, предложений корзины и маркетинговых стратегий после покупки. В случае розничного бизнеса многие результаты правил ассоциации общеизвестны, например, гамбургер с картофелем фри или детское питание с подгузниками; однако необычные отношения — это ценные открытия, которыми бизнес может воспользоваться. Обратной стороной является то, что анализ ассоциаций может также выявить ложные связи между элементами. Имея дело с данными, содержа-

щими миллиарды транзакций, мы обнаружим транзакции со всеми видами возможностей со странными комбинациями наборов элементов (например, никотиновый пластырь и сигареты). Для успешного применения результатов ассоциативного анализа необходимы аналитические навыки и знания бизнеса. Модельный результат ассоциативного анализа можно представить в виде набора правил, подобных приведенному ниже:

Это правило указывает, что, исходя из истории всех транзакций, если товар А находится в транзакции или корзине, существует высокая вероятность появления товара В в той же транзакции. Здесь пункт А является антецедентом или предпосылкой правила, а пункт В является следствием или заключением правила. Антецедент и следствие правила могут содержать более одного элемента, например Item A и Item C. Чтобы извлечь из данных такие правила, нам потребуется проанализировать все предыдущие транзакции покупок клиентов. В розничном бизнесе в день совершаются миллионы транзакций с тысячами единиц хранения запасов (SKU), которые являются уникальными идентификаторами продаваемого и хранящегося продукта или товара. Следовательно, двумя ключевыми моментами ассоциативного анализа являются вычислительное время и ресурсы. Однако за последние два десятилетия были разработаны новые и более эффективные алгоритмы для решения этой проблемы.

Базовый ассоциативный анализ касается только совпадения одного элемента с другим. Более сложный анализ может учитывать количество вхождений, цену, последовательность появления и т. д. Метод поиска правил ассоциации посредством интеллектуального анализа данных включает следующие последовательные шаги:

Шаг 1: Подготовьте данные в формате транзакции. Алгоритму ассоциации необходимо, чтобы входные данные были отформатированы в определенном формате.

Шаг 2. Составьте краткий список часто встречающихся наборов элементов. Наборы предметов представляют собой комбинации предметов. Алгоритм ассоциации ограничивает анализ наиболее часто встречающимися элементами, поэтому окончательный набор правил, извлеченный на следующем этапе, является более значимым.

Шаг 3. Создайте соответствующие правила ассоциации из наборов элементов. Наконец, алгоритм генерирует и фильтрует правила на основе показателя процента.

Для начала давайте рассмотрим медиа-сайт, такой как BBC или Yahoo News, с такими категориями, как новости, политика, финансы, развлече-

ния, спорт и искусство. Сеанс или транзакция в этом примере — это одно посещение веб-сайта, при котором один и тот же пользователь получает доступ к контенту из разных категорий в течение определенного периода сеанса. Новый сеанс обычно начинается после 30 минут бездействия. Сессии очень похожи на транзакции в традиционной модели, и доступные страницы могут быть связаны с приобретенными товарами. На новостных интернет-сайтах элементами являются посещения таких категорий, как «Новости», «Финансы», «Развлечения», «Спорт» и «Искусство». Мы можем собрать данные, как показано в Таблице 6.1, со списком сеансов и категорий мультимедиа, к которым осуществляется доступ во время данного сеанса. Наша цель в этой задаче интеллектуального анализа данных — найти ассоциации между категориями СМИ.

Для анализа ассоциации этих категорий мультимедиа нам понадобится набор данных в определенном формате транзакции. Чтобы начать анализ связей, было бы полезно привести данные в формат, показанный в Таблице 6.2.

Поиск знаний в больших объемах данных — важная задача. Ассоциативные правила позволяют находить связи между событиями. Например, покупатель, приобретающий «Хлеб», также приобретет и «Молоко» с большой вероятностью.

Первые алгоритмы поиска ассоциативных правил были разработаны еще в начале 90-х годов [18]. Эта задача возникла, как задача поиска шаблонов покупок, совершаемых в супермаркетах как анализ рыночной корзины (market basket analysis).

Каждая покупка транзакция — набор товаров, купленных за один визит, этот набор называют рыночной корзиной.



Market Basket Analysis

Market Basket Analysis is one of the key techniques used by large retailers to uncover associations between items.



www.edureka.co

Association Rule Mining




www.edureka.co

Рассмотрим несколько определений. Пусть $I = \{i_1, i_2, i_3, \dots, i_n\}$ — множество элементов (товаров).

Далее D — множество транзакций, где T — это множество элементов из I , $T \subseteq I$. Каждая транзакция представляет собой бинарный вектор, где $t[k] = 1$, если i_k элемент присутствует в транзакции, иначе $t[k] = 0$. Мы говорим, что транзакция T содержит X , некоторый набор элементов из I , если $X \subset T$.

Ассоциативным правилом называется импликация $X \Rightarrow Y$, где $X \subset I$, $Y \subset I$ и $X \cap Y = \emptyset$.

Association Rule Mining



www.edureka.co

Рассмотрим понятие **поддержка (support)**.

Правило $X \Rightarrow Y$ имеет поддержку s (support), если $s\%$ транзакций из D , содержат $X \cup Y$, $\text{supp}(X \Rightarrow Y) = \text{supp}(X \cup Y)$. Достоверность правила показывает какова вероятность того, что из X следует Y .

Покупка 1				
Покупка 2				
Покупка 3				
Покупка 4				
Покупка 5				
Покупка 6				
Покупка 7				
Покупка 8				

Мера 1: поддержка.

Поддержка показывает *частоту товарного набора*,. В табл. 1 {яблоко} появляется в четырех из восьми покупок, значит, его поддержка 50 %. Товарные наборы могут содержать и несколько элементов. Например, поддержка набора {яблоко, пиво, рис} — два из восьми, то есть 25 %.

В ряде случаев для удаления наборов с низкой частотой вводят *порог поддержки*.

$$\text{Поддержка } \{\text{яблоко}\} = \frac{4}{8}$$

Мера **достоверностью (confidence)** показывает частоту появления Y вместе X , что выражается как $X \Rightarrow Y$. Мера Достоверность {яблоко $\Rightarrow$ пиво} 75 %.

$$\text{Достоверность } \{\text{яблоко} \rightarrow \text{пиво}\} = \frac{\text{Поддержка } \{\text{яблоко, пиво}\}}{\text{Поддержка } \{\text{яблоко}\}}$$

Мера 3: лифт отражает *частоту появления X и Y и учитывает их частоты*.

$$\text{Лифт } \{\text{яблоко} \rightarrow \text{пиво}\} = \frac{\text{Поддержка } \{\text{яблоко, пиво}\}}{\text{Поддержка } \{\text{яблоко}\} \times \text{Поддержка } \{\text{пиво}\}}$$

Усли лифт равен единице, что означает отсутствие связи между товарными наборами. Значения лифта больше единицы означают, что товар Y вероятно купят вместе с товаром X, а значение меньше единицы — что их совместная покупка маловероятна.

edureka!

Association Rule Mining

A $\Rightarrow$ B

$$Support = \frac{freq(A, B)}{N}$$

$$Confidence = \frac{freq(A, B)}{freq(A)}$$

$$Lift = \frac{Support}{Supp(A) \times Supp(B)}$$

www.edureka.co

Покупка	Поддержка	Достоверность	Лифт
Пиво $\rightarrow$ Газировка	1,38 %	17,8 %	1,0
Пиво $\rightarrow$ Ягоды	0,08 %	1,0 %	0,3
Пиво $\rightarrow$ Мужская косметика	0,09 %	1,2 %	2,6

Задача нахождения ассоциативных правил нахождению наборов которые встречаются достаточно часто и создание правил из наборов элементов с достоверностью выше некоторого порога.

Алгоритм APrіori — [19] один из первых. Его отличительная особенность правильный выбор парметров минимальная поддержка и минимальная достоверность.

Принцип APrіori утверждает, что редкий товарный набор влечет что большие наборы, которые его включают, тоже будут редкими.

Apriori Algorithm - 1st Iteration

C1	
TID	Items
T1	1 3 4
T2	2 3 5
T3	1 2 3 5
T4	2 5
T5	1 3 5

→

Itemset	Support
{1}	3
{2}	3
{3}	4
{4}	1
{5}	4

Apriori Algorithm - 2nd Iteration

Only Items present in F1	
C2	
TID	Items
T1	1 3 4
T2	2 3 5
T3	1 2 3 5
T4	2 5
T5	1 3 5


→

Itemset	Support
{1,2}	1
{1,3}	3
{1,5}	2
{2,3}	2
{2,5}	3
{3,5}	3

→

F2	
Itemset	Support
{1,3}	3
{1,5}	2
{2,3}	2
{2,5}	3
{3,5}	3

Item sets with support value less than min. support value (i.e. 2) are eliminated



Товарные наборы в пределах пунктирной линии будут отброшены.

Ассоциативные правила можно использовать при выделении групп покупателей, анализе клиентов и т.п. Но этим не ограничивается круг использования ассоциативных правил, одно из важных применений — анализа текста (Text Mining). Поиск новых тем в научных исследованиях.

Таким образом, впервые применив ассоциативные правила для анализа покупок они широко используются во многих сфера интеллектуального анализа данных.

Глава 3

Визуальная аналитика многомерных данных

3.1. Визуально-интерактивная аналитика

За последнее десятилетие анализ многомерных данных стал одним из основных направлений прикладной математики, активно развивающимся и применяющимся практически во всех областях исследований. Под анализом многомерных данных, как правило, понимается совокупность методов и алгоритмов, позволяющих получить максимально возможную информацию о массиве числовых данных, расположенных в некоторой области многомерного пространства. Заметим, что всегда есть риски, связанные с любой процедурой, которая обрабатывает или преобразовывает данные [1,2]. Важно отметить, что цель вычислений — это новые знания, а не числа. При этом проблема заключается в том, чтобы данные расчетов были представлены в адекватной форме и для лучшей интерпретации визуализированы. При выборе метода визуализации необходимо помнить, что неправильные предположения о свойствах данных или их источника, без учета особенностей зрительной системы человека, могут привести к ложным выводам.

Для этого в компьютерной графике применяются различные приемы, в том числе использование перспективы, удаление скрытых линий и поверхностей, применение стереографических изображений для представления образа объекта, которое обманывает нашу зрительную систему в восприятии пространства, или объемное изображение, нарисованное на явно плоском экране компьютера. Если мы смотрим на изображении в гарнитуре виртуальной реальности, мы можем добавить параллакс движения, который поможет нам воспринимать глубину, даже если дисплей перед нами на самом деле не более, чем массив цветных точек.

Наша сетчатка глаза получает только проекцию трехмерного мира, по-

этому визуализация будет в основном ограничена тремя измерениями, к которому можно добавить анимацию.

Разработка и применение методов визуально-интерактивной анимации в задачах обработки и представления многомерных данных, позволяет повысить качество аналитических выводов при решении различных задач исследования многомерных данных.

С этой точки зрения визуальная аналитика (Visual Analytics) представляет собой объединение методов и подходов, реализующих такие активно развивающиеся направления, как научная визуализация (Scientific Visualization), визуализация информации и информационных процессов (Information Visualization), анализ многомерных данных (Multivariate Data Analysis).

Остановимся подробнее на понятии «научная визуализация». Научная визуализация — это преобразование абстрактных данных, полученных из наблюдения или моделирования, в легко понятные изображения [15]. Научная визуализация играет важную роль в процессе научных открытий во многих областях современной науки. Методы научной визуализации помогают ученым в исследовании и анализе результатов компьютерного моделирования, измерения данных со сканеров, финансовых записей. Одно из важных направлений, которые развиваются под эгидой научной визуализации, — это использование взаимодействия человека и компьютера в управлении и интерпретации сложных процессов моделирования, включающие в себя объемные наборы данных в различных задачах численного моделирования [15].

Поскольку зрение доминирует в нашем взаимодействии с миром, лучше всего донести математические абстракции и результаты моделирования через посредничество компьютерной графики.

Целью визуально-интерактивного моделирования является обеспечение поддержки принятия оперативного и точного решения человеком. Визуальная аналитика объединяет различные методы и технологии во всех интегрируемых ею дисциплинах с целью максимально эффективного обеспечения взаимодействия «человек-компьютер».

Общая цель визуально-интерактивного моделирования — исследование многомерного объема данных и получение максимально возможной информации об изучаемом облаке данных и обеспечение максимального понимания происходящих в нем процессов. Визуальная аналитика призвана организовать человеко-машинный интерфейс, усиливающий человеческие аналитические способности с помощью следующих методов:

- о расширение оперативной памяти человека за счет использования ви-

зуализации,

- размещение информации в пространстве в соответствии с временными соотношениями,
- организация управляемой среды для работы пользователя в пространстве параметрических значений,
- организация визуального представления и интерфейсов, обеспечивающих человеку возможность сразу видеть, исследовать и понимать огромные информационные объемы.

Для числа измерений меньше трех реализация визуального анализа данных не представляет особой сложности, потому, что человек, обладает двумерным зрением и укладывающимися в сознание геометрическими образами и представлениями для пространств с числом измерений $n \geq 3$. Для многомерных пространств с числом измерений подобных геометрических образов у человека нет. Следовательно, необходимо осуществлять проецирование во вложенные пространства со стандартным числом измерений.

Как правило при численном решении практических задач получают большие массивы многомерных данные. Эти результаты нуждаются в технологиях многомерной визуализации.

Визуализация данных — представление в наглядной форме данных эксперимента или результатов теоретического исследования.

Первым выбором в визуализации множества данных является ортогональное проецирование на плоскость первых двух главных компонент (или 3-мерное пространство первых трёх главных компонент).

Плоскость проецирования является, по сути плоским двумерным «экраном», расположенным таким образом, чтобы обеспечить «картинку» данных с наименьшими искажениями. Такая проекция будет оптимальна (среди всех ортогональных проекций на разные двумерные экраны) в трех отношениях:

Визуализация данных является одним из наиболее широко используемых приложений метода главных компонент и его нелинейных обобщений.

3.2. Методы анимации в представлении данных

Помимо трех пространственных измерений, единственное другое измерение, которое мы встречаем в реальном мире — время. Разумно использовать время в анимации для целей визуализации.

Важно, что «анимация» — это движение, сгенерированное только программой, а не пользователем. При достижении определенной частоты син-

теза кадров существует естественная тенденция связывать различные статические изображения вместе (бета-движение). Изображения, показанные быстрее, чем около 20 Гц, будут выглядеть непрерывно, без мерцания. Во время анимации обработка каждого кадра также должна включать восстановление визуализации для каждого нового временного шага или, возможно, перечитывания файла данных для получения нового временного шага.




Рис. 3.1. Движение во времени

Одной из альтернатив анимации является «мозаика» дисплея с различными кадрами. На рисунке 3.1 показаны сечения функции показанные как движение во времени. Заметим что, анимация, дает общее представление о развитии функции, в то время как взгляд на кадры показывает мелкие детали, которые в противном случае могли быть пропущены. Поэтому в идеале мы стремимся обеспечить оба механизма для отображения многомерных наборов данных.

Более существенные проблемы возникают при томографии головы человека 3.2. Чем больше сечений представляют весь объем, тем меньше мы видим, поскольку мешают промежуточные сечения. В этом случае можно использовать анимацию, при этом следует учитывать движение глаз при восприятии. Следует эффект саккады, что позволит скрыть изменения в деталях между кадрами.

Человек видит трехмерное изображение, а создает двухмерные проекции на сетчатке глаза, мозг достраивая картинку.





Рис. 3.2. Данные томографии



★ Движение взгляда по лицу одной из самых красивых женщин в истории

Сечения, показывающие шкалу плотности серого, являются способом визуализации данных в объеме, но чем больше срезов включено, тем труднее становится увидеть их содержание.




Рис. 3.3. Изолинии на сечениях

Основной особенностью предложенного подхода визуально-интерактивного моделирования многомерных пространств с числом измерений $n > 3$ является динамическое представление 2D моделей сечений исследуемых данных. Эффект многомерности достигается за счет выбора 2D моделей, вариативности направлений динамических сечений и использование возможностей стереоскопического зрения.

Непрерывные числовые данные $u(x, y, z)$ можно представить поверхностями уровня. В этом случае можно отображать поверхности уровня


$$S(t) = \{(x, y, z) \mid u(x, y, z) = t\}.$$

Меняя динамически параметр t можно получить представление о распределении $u(x, y, z)$.

Одним из таких способов показывать на сечениях не всю информацию, а только часть, например изолинии или используя цвет показывать информацию только в узлах сетки.

Использование изолиний позволяет показывать одновременно несколько близких сечений.

На рисунке 3.3 пять сечений, образованные плоскостями $P_i, i = 1, \dots, 5$. При этом можно менять расстояние между плоскостями, скорость движения, толщина и прозрачность.



Использование стереопар

Можно использовать стерео пары. Для просмотра можно использовать: стереоскоп, стереодисплеи, виртуальные шлемы. Самое простое загрузить стереопары в виде видеофайла на смартфон.

Глава 4

Математические модели и методы агрегирования данных больших объемов

4.1. Определение понятия и математических моделей агрегирования данных

Агрегирование данных применяется как метод предварительной обработки эмпирических данных для последующего численного моделирования. Известно, что агрегацию часто используют в задачах анализа данных, когда необходимо перейти от данных с высокой степенью детализации к более обобщенному представлению. Примером таких процедур является простое суммирование, вычисление среднего, медианы, диапазона максимальных или минимальных значений т.е. интервальных данных, построение функции распределения.

Процедура агрегирования имеет свои преимущества и недостатки. С положительной стороны подробные данные часто являются неустойчивыми из-за воздействия случайных факторов, затрудняя обнаружение общих тенденций и шаблонов данных. Во многих случаях полезно рассматривать большие числовые данные в агрегированной форме, такой как суммирование или среднее. Важно иметь в виду, что использование таких процедур агрегирования, как усреднение, исключение экстремальных значений, процедура сглаживания может привести к потере важной информации. Поэтому выбор метода агрегирования является важной задачей, поскольку без предварительного исследования легко получить дополнительную неопределенность, которой нет в исходной постановке.

Для агрегирования данных используются различные математические модели. В тех случаях, когда данные могут быть представлены частотными

распределениями рассматриваемых характеристик или признаков, предлагается использовать кусочно-полиномиальные модели. Частным примером кусочно-полиномиальных моделей является гистограмма, которая представляет собой кусочно-постоянную функцию агрегирования. Кроме гистограмм для агрегации полезно рассмотреть частотные полигоны, сплайны.

Статистическим аналогом плотности распределения непрерывной генеральной совокупности X является гистограмма — кусочно-постоянная функция $\hat{f}_n$, значение которой на каждом интервале определяются формулой

$$\hat{f}_n(x) = \frac{p_i}{h}, x \in (x_{i-1}, x_i), i = 1, \dots, n,$$

где p_i — частота из дискретного статистического ряда; $h = x_i - x_{i-1}$ — длина интервала.

Гистограмма по форме представляет собой прямоугольники, ориентированные относительно оси ординат или абсцисс. Пример гистограммы для статистического ряда, содержащего четыре интервала, показан на рисунке 4.1. Легко заметить, что площадь заштрихованной фигуры (площадь под гистограммой) равна единице.

Соединив точки гистограммы с абсциссами, на рисунке 4.1 можно построить полигон частот.

По виду полигона выдвигается основная гипотеза о характере распределения генеральной совокупности: нормальное (гауссовское распределение), показательное (экспоненциальное распределение), равномерное распределение и т.д. Для полигона на рисунке 4.1 основной гипотезой будет, очевидно, гипотеза о нормальном законе распределения.




Рис. 4.1. Гистограмма и частотный полигон

Поскольку сплайн является кусочно-полиномиальной функцией, то его можно рассматривать как функцию агрегирования данных. Функция агрегирования выполняет численные обработки наборов данных и возвращает сплайн-значения [4].

Поскольку сплайн есть совокупность функций, каждая из которых задана на своем подмножестве значений аргумента, то сплайн в общем случае можно записать следующим образом

$$s(x) = \sum s_i \psi_i(x), \quad (4.1)$$

где s_i — коэффициенты, ψ_i — базисные функции сплайна.

4.2. Построение гистограммы

Программа по построению гистограммы и полигона состоит из процедуры считки файла и записи данных в массив, состоящий из 10000 элементов. Основные переменные данного блока — это текстового типа, в которой хранятся данные с переносом строки в формате «0.000», переменная, в которую записывается число, каждую итерацию цикла, который обходит каждую строку переменной. Переменная — это массив вещественного типа данных, размер которого 10000 элементов, — индекс массива для заполнения.

Самый основной блок — процедура построения гистограммы и полигона. Данную процедуру можно разделить на две части, первая — это аналитическая часть, где заполняется вся необходимая информация для построения гистограммы и полигона.

В процессе заполнения данных, переменная равна количеству шагов гистограммы и полигона, это длина одного шага, — количество обрабатываемых данных, в нашем случае 10000 экспериментальных данных. Переменные и отвечают за масштаб гистограммы. — это массив, который хранит в себе шаг с -ой размерностью.

Известно, что величина шага h существенно влияет на общий вид гистограммы. С уменьшением шага величина дисперсии возрастает, так как каждый интервал содержит при этом лишь небольшое число значений.

4.3. Построение сплайна, проходящего через середины гистограммы

При большом количестве узлов интерполяции приходится использовать интерполяционные полиномы высокой степени, что создает определенные неудобства при вычислениях. Можно избежать высокой степени интерполяционного многочлена, разбив отрезок интерполяции на несколько ча-

стей с построением на каждой части самостоятельного интерполяционного многочлена. Однако такое интерполирование обладает существенным недостатком: в точках сшивки разных интерполяционных полиномов будет разрывной их первая производная, поэтому для решения задачи кусочно-линейной интерполяции используют особый вид кусочно-полиномиальной интерполяции — сплайн-интерполяцию [20].

Эрмитов кубический сплайн — сплайн, построенный из кубических полиномов с использованием эрмитовой интерполяции [21]. Интерполируемая функция задается не только своими значениями f_i в точках x_i , но и ее первыми производными p_i . На отрезке $[x_0, x_1]$ эрмитов сплайн имеет вид:

$$s(x) = f_0 sp(t, 1) + f_1 sp(t, 2) + hp_0 sp(t, 3) + hp_1 sp(t, 4);$$

где $h = x_1 - x_0$, $t = (x - x_0)/h$, $sp(t, 1) = 1 - 3t^2 + 2t^3$; $sp(t, 2) = 3t^2 - 2t^3$; $sp(t, 3) = t(1 - t)^2$; $sp(t, 4) = -t^2(1 - t)$.

Используя программу, необходимо построить гистограмму на отрезке $[0;4]$ с шагом и эрмитов кубический сплайн по точкам массива, где являются середины столбцов гистограммы, а элементами массива высоты столбцов гистограммы.

На рисунке 4.2 изображено построение сплайна (пунктирная линия) по гистограмме.




Рис. 4.2. Эрмитов кубический сплайн, построенный по гистограмме

На рисунке 4.2 видно, что эрмитов кубический сплайн хорошо приближает исходную функцию (красная линия).

4.4. Построение сглаживающего сплайна

Обычно набор экспериментальных данных получается с некоторой погрешностью. В этом случае необходимо провести сглаживающую кривую,

которая не проходит через экспериментальные точки, но в то же время отражает исследуемую зависимость.

Наиболее распространенным методом аппроксимации экспериментальных данных является метод наименьших квадратов (МНК). Обозначим узлы исходной таблицы данных через x_i , $i = 0, \dots, n$. Считаем известными значения экспериментальных данных в узловых точках f_i . Для сглаживания дискретной зависимости будем использовать эрмитовые сплайны (4.1). Критерием близости в методе наименьших квадратов является требование минимальности суммы квадратов отклонений от аппроксимирующей функции до экспериментальных точек

$$\sum_{i=0}^n (s(x_i) - f_i)^2 \rightarrow \min.$$

Программа, использующаяся для построения аппроксимирующего сплайна, использует для процесса моделирования эмпирические данные, представленные в текстовом документе формата TXT. Результатом работы является набор значений, по которым можно отрисовать график сплайна, а также провести сравнение с исходными данными. Результат, полученный в результате работы программы, представлен на рисунке 2.12.




Рис. 4.3. Сравнение аппроксимирующего сплайна и функции плотности вероятности

Из рисунка 4.3 видно, что построенный сглаживающий сплайн значительно лучше приближает функцию плотности вероятности чем интерполирующий.

Таким образом, используя данные середины столбцов гистограммы, сглаживающий сплайн дает наилучшее приближение к функции плотности вероятности.

Глава 5

Методические материалы к выполнению самостоятельных заданий

5.1. Задания для самостоятельной работы

В рамках изучения дисциплины необходимо провести обработку экспериментальных данных, под которой подразумевается преобразование данных к виду, удобному для использования, перевод ответов природы с языка измерения на язык уточняемой модели. Данные – факты, сведения о реальных и абстрактных лицах, предметах, объектах, явлениях и событиях, соответствующие определенной предметной области и представленные в графическом, символическом, звуковом, графическом и других форматах. Информация – данные определенной области, организованные и имеющие смысловое значение, необходимые для принятия решения потребителем, а также для реализации других функций и действий. Знание — вид информации, отражающий знание, опыт и восприятие эксперта в определенной области. Характеристики знания: — внутренняя интерпретируемость; — новизна; — практическая значимость; — структурируемость; — связанность и др.

Задание 1.

- выбрать ОИ в соответствии с темой научного исследования; - разработать матрицу признаков; - создать матрицу данных; - изучить основные принципы работы с ПАП «Loginom»; - осуществить импорт данных; Оформить отчет.

Задание 2.

На основе импортированных в ПАП «Loginom» данных - провести преобработку данных; - провести процессинг данных, включая исследование корреляционных связей и моделирование зависимостей в данных; Оформить отчет

Задание 3.

Провести постобработку данных, включая интерпретацию и визуализацию результатов; сделать обзор полученных результатов с точки зрения полученных знаний и применения результатов в научных исследованиях. Оформить отчет

5.2. Пример содержательного описания объекта исследования

Объект исследования — выборка из 55 участков автомобильной дороги города Л, на которых проводятся измерения выбросов.

Автомобильная дорога — объект транспортной инфраструктуры, предназначенный для движения транспортных средств и включающий в себя земельные участки в границах полосы отвода автомобильной дороги и расположенные на них или под ними конструктивные элементы (дорожное полотно, дорожное покрытие и подобные элементы) и дорожные сооружения, являющиеся ее технологической частью, защитные дорожные сооружения, искусственные дорожные сооружения, производственные объекты, элементы обустройства автомобильных дорог.

Основными параметрами и характеристиками, определяющими транспортно-эксплуатационные показатели дороги, являются:

- геометрические параметры, к которым относятся, ширина проезжей части и краевых укрепленных полос, общая и укрепленная ширина обочин, продольные уклоны,
- радиусы кривых в плане и профиле, уклоны виражей и расстояние видимости;
- прочность и состояние дорожной одежды проезжей части и обочин;
- ровность и сцепление покрытий проезжей части и обочин;
- состояние земляного полотна;
- состояние и работоспособность водоотвода;
- габариты, грузоподъемность и состояние мостов, путепроводов и других искусственных сооружений;
- состояние элементов инженерного оборудования и обустройства дороги .

Предмет научного исследования участка дороги составляют следующие признаки:

- количество ТС;

- категория дороги;
 - состояние погоды;
 - состояние проезжей части;
 - наличие освещения;
 - недостатки транспортно-эксплуатационного содержания улично-дорожной сети;
 - техническое состояние ТС
- Источники данных:(указывать обязательно)

5.3. Вопросы для самопроверки

1. Раскройте содержательный смысл понятия «интеллектуальность»
2. Раскройте содержательный смысл понятий данные, информация, знания
3. Понятие измерения и измерительные шкалы.
4. Раскройте понятие программно-аналитические системы.
5. Раскройте содержательный смысл понятия интеллектуальная обработка данных.
6. Неопределенные данные. Классификация неопределенностей в данных.
7. Модели неопределенных данных
8. Модели данных и классификация задач обработки.
9. Очистка, преобразование и трансформация данных.
10. Что такое процессинг, предпроцессинг и постпроцессинг?
11. Что такое большие временные ряды?
12. Классификация неопределенности в данных.
13. Понятие неполные, неточные и неопределенные данные.
14. Способы и модели представления данных.
15. Агрегирование данных. Математические модели для агрегации данных больших объемов.
16. Вычислительный вероятностный анализ и его применение в теории и практике ИАД
17. Исследование связей и корреляционный анализ данных.
18. Что такое временные ряды распределений
19. Регрессионные методы и модели на больших данных.
20. Функциональная регрессия. Примеры практических задач.
21. Метод статистических испытаний.
22. Численные методы решения математических задач при помощи моделирования случайных процессов и событий. Метод Монте-Карло.

23. Интерполяция, экстраполяция и сглаживание, дифференцирование и интегрирование сплайнами.
24. Технология Data Mining. Технология KDD. Технология визуально-интерактивного моделирования.
25. Программно-аналитические платформы Deductor, Loginom. Этапы разработки, использования и внедрения в практику.
26. Надежные вычисления
27. Функциональный и символьный анализ данных. Плюсы и минусы.
28. Раскройте понятие метод ассоциативных правил.
29. В каких случаях применяется метод агрегирования данных.

Список литературы

1. Анналин Ы., Кеннет С. Теоретический минимум по Big Data. Всё, что нужно знать о больших данных. — СПб.: Питер, 2019. — 208 с.
2. Будущее искусственного интеллекта / Под ред. К.Е. Литвина и Д.А.Поспелова. — М.: Наука, 1991.
3. Брюс, П. Практическая статистика для специалистов Data Science. — СПб.: БХВ-Петербург, 2018. — 304 с.
4. Владстон Ф., Мото П. Теоретический минимум по Computer Science. Сети, криптография и data science. — СПб.: Питер, 2022. — 288 с.
5. Вукобратович М., Стокич Д. Управление манипуляционными роботами. — М.: Наука, 1985.
6. Голицин Г.А., Фоминых И.Б. Интеграция нейросетевой технологии с экспертными системами // Труды 5-й национальной конференции по искусственному интеллекту (КИИ-96). - Казань, 1996.
7. Грас Д. Data Science. Наука о данных с нуля. — СПб.: БХВ-Петербург, 2020. — 416 с.
8. Искусственный интеллект. В 3 кн. Кн. 2. Модели и методы / Под ред. Д.А. Поспелова. - М.: Радио и связь, 1990.
9. Кандрашина Е.Ю., Литвинцева Л.В., Поспелов Д.А. Представление знаний о времени и пространстве в интеллектуальных системах / Под ред. Д.А. Поспелова. — М.: Наука, 1989.
10. Лорьер Ж.-Л. Системы искусственного интеллекта / Пер. с фр. — М.: Мир, 1991.
11. Майер-Шенбергер, В. Большие данные. Революция, которая изменит то, как мы живем, работаем и мыслим / — М. : Манн, Иванов и Фербер, 2014. — 240 с.

12. Медведев В.С., Лесков А.Г., Ющенко А.С. Системы управления манипуляционных роботов. — М.: Наука, 1978.
13. Мыльников Л. А. Статистические методы интеллектуального анализа данных. — СПб.: БХВ-Петербург, 2021. — 240 с.
14. Прикладные нечеткие системы / Под ред. Т. Тэрано, К. Асаи, М. Сугэно. — М.: Мир, 1993.
15. Попова О.А. Визуально-интерактивная анимация в задачах анализа данных // Информатизация и связь №5 2019 С. 93–96
16. Сапрыкин О. Н. Интеллектуальный анализ данных: учебное пособие / — Самара: Издательство Самарского университета, 2020. — 80 с.
17. Юревич Е.И. Основы робототехники. — Л.: Машиностроение, 1985.
18. R. Agrawal, T. Imielinski, A. Swami 1993. Mining Associations between Sets of Items in Massive Databases. In Proc. of the 1993 ACM-SIGMOD Int'l Conf. on Management of Data, 207–216.
19. R. Agrawal, R. Srikant Fast Discovery of Association Rules, In Proc. of the 20th International Conference on VLDB, Santiago, Chile, September 1994.